

TP traitement avancé des sons - Séparations de sources

Dans ce TP, nous allons implémenter le réseau UNet vu en cours pour la séparation de voix chantées. Le choix de la librairie de deep learning utilisée est libre. Le rendu du TP consiste en :

- un rapport court (2 pages max) présentant vos choix d'implémentation et vos résultats
- Un notebook présentant votre modèle
- Deux audios séparés (soit de la base de test, soit de votre propre bibliothèque)

1 Article

Tout d'abord, téléchargez l'article <https://openaccess.city.ac.uk/id/eprint/19289/>. Familiarisez-vous avec le modèle et la façon de reconstruire l'audio séparé à partir du mix et du modèle.

2 Données

Nous utiliserons la base de données MUSDB. Pour la télécharger : <https://zenodo.org/records/1117372>. Cette base de données est fournie avec une librairie de parsing/processing python. La documentation est ici : <https://github.com/sigsep/sigsep-mus-db>. Pour l'installer, vous pouvez utiliser pip (!`pip install musdb`).

Pour le début du TP, vous pouvez utiliser la base de données restreintes à 7 secondes d'audio en executant (après l'installation du package musdb) :

```
import musdb
mus = musdb.DB(download=True)
mus[0].audio
```

Dans un premier temps, adaptez le générateur naïf fourni par la librairie musdb (dont on rappelle le code ci après) pour pouvoir générer des batch de taille `batch_size` de spectrogrammes de mix et de voix séparées. Ces spectrogrammes doivent utiliser les paramètres d'analyse de l'article.

```
while True:
    track = random.choice(mus.tracks)
    track.chunk_duration = 5.0
    track.chunk_start = random.uniform(0, track.duration - track.chunk_duration)
    x = track.audio.T
    y = track.targets['vocals'].audio.T
    yield x, y
```

En suivant les paramètres d'analyse de l'article, on observe un fort taux de recouvrement entre deux spectrogrammes de 128 trames. Proposez une solution d'implémentation pour ce problème (à détailler dans le rapport).

3 Modèle

A partir de l'article, implémentez le modèle U-Net pour la séparation de voix chantée. A l'aide du générateur défini en partie 1, entraînez votre modèle sur une sous partie de musdb dans un premier temps (les entraînements peuvent être longs).

4 Reconstructions audio

Une fois votre modèle entraîné, utilisez la base de test de musdb pour extraire les spectrogrammes de voix séparées. Une fois ces spectrogrammes extraits, utilisez la phase du mix et la transformée de Fourier inverse pour obtenir les audios séparés.

5 Résultats

Avec les audios séparés de la base de test de musdb, utilisez la librairie `museval` pour estimer les métriques de séparations de sources usuelles (SIR, SAR et SDR) de votre modèle. Vous pouvez adapter le code fournit par la librairie `musdb` pour estimer ces métriques, rappelé ici :

```
import museval
# provide an estimate
estimates = {
    'vocals': np.random.random(track.audio.shape),
    'accompaniment': np.random.random(track.audio.shape)
}
# evaluates using BSSEval v4, and writes results to './eval'
print(museval.eval_mus_track(track, estimates, output_dir="./eval")
```

Comment se comparent vos résultats avec ceux de l'article original ? Commentez.